

客户端 post /v1/chat/completions



Tokenizer Manager: 解析请求 → 生成 input-ids



Scheduler: 请求入队 → Continuous Batching



Radix Cache: 最长前缀分配 命中 → 复用已有KV



Token-to-KV Pool 按Page分配内存

逻辑页 → 物理页映射



Prefill 只计算未命中的token



Decode 逐token生成

读 paged KV → Attention



采样 → 下一个token



Eos / max-tokens

true: Detokenizer → Json

false: → 回到 Decode